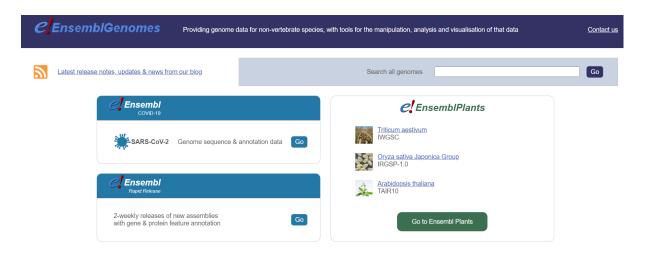
Libro de respuestas Taller herramientas de Ensembl y Ensembl Genomes

Actividad 1.

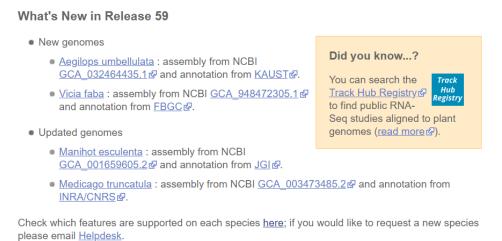
1. Ir al portal de Ensembl Genomes que corresponda

Como estamos trabajando con *V. vinifera*, debemos ir a *Ensembl plants* (https://plants.ensembl.org/)



2. Registrar la versión actual de Ensembl Genomes

Es la versión 59



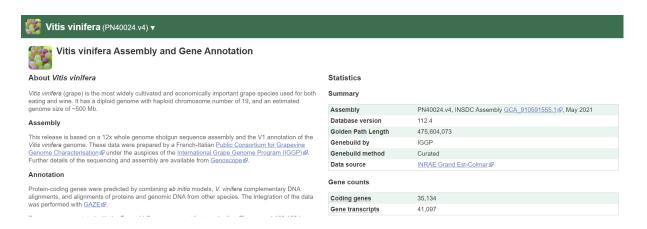
3. Encontrar el sitio para V. vinifera



El sitio es https://plants.ensembl.org/Vitis_vinifera/Info/Index

4. Registrar el nombre del *assembly* (genoma de referencia), su tamaño en pb, número de cromosomas y cantidad de genes anotados

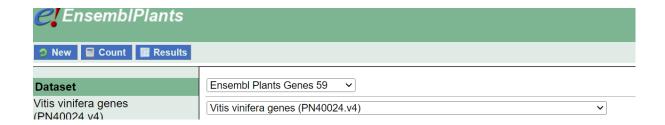
Assembly PN40024.v4, INSDC Assembly GCA_910591555.1, May 2021. Tamano: 475,604,073. Coding genes: 35,134



Actividad 2:

1. En Biomart, seleccionar el dataset correspondiente

Debemos ir a BioMart (https://plants.ensembl.org/biomart/martview/) y seleccionar como DATABASE: Ensembl Plants Genes 59) y como DATASET: Vitis vinifera genes



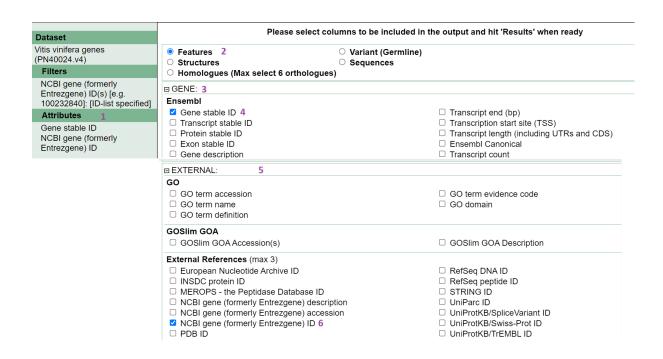
2. Ingresar como filtro nuestra lista de genes upregulados a 72h post infección (cuyos IDs están codificados en formato NCBI)

Primero debo establecer los filtros. Puntualmente en esta actividad, acotar la búsqueda a mi lista de genes. Para esto, FILTERS (1) \rightarrow GENE (2) \rightarrow click en Input external references ID list (3) \rightarrow Desplegable, elegir NCBI gene IDs (4) \rightarrow En choose file, subir mi lista de genes (unique 72h UP.txt, 5)

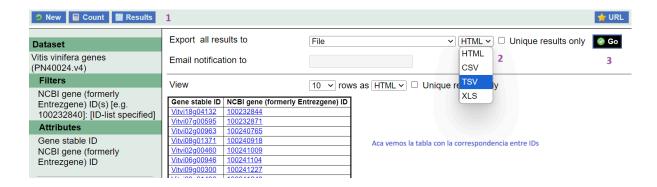


3. Obtener para cada gen (cuyo ID está codificado en formato NCBI) el ID usado por la comunidad científica para esa especie (puntualmente para *Vitis*, se llaman "Vitvi_XXX")

Luego obtener la correspondencia entre IDs de NCBI y IDs propios de Vitis. Para esto, ir a Attributes (1), seleccionar Features (2), GENE (3), Gene stable ID (4, así se llama el ID usado por la comunidad), EXTERNAL (5), NCBI gene ID (6)

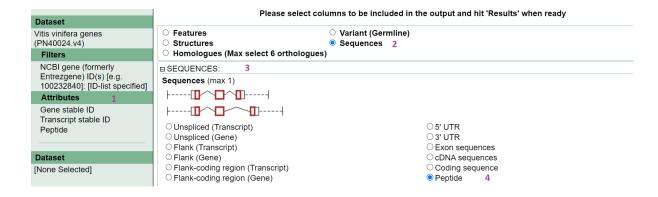


Luego podemos exportar esos resultados en formato .tsv. Para esto, vamos a Results (1), luego seleccionamos en el desplegable el formato (2), finalmente descargamos con Go (3).



4. Obtener las secuencias de las proteínas codificadas por estos genes (formato FASTA, aminoácidos).

Luego, para recuperar las secuencias de las proteínas codificadas por estos genes de la lista, ir a Attributes (1), seleccionar Sequences (2), desplegar SEQUENCES (3), seleccionar Peptide (4)



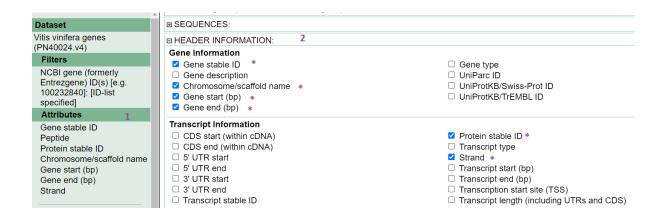
Luego para descargar los datos en formato FASTA, ir a Results (1), Go (2)



Pueden mirar cuales son las particularidades del formato FASTA.

5. Mejorar los encabezados, para hacerlos informativos: Gene stable ID, cromosoma, posición de inicio, posición final, hebra y protein stable ID

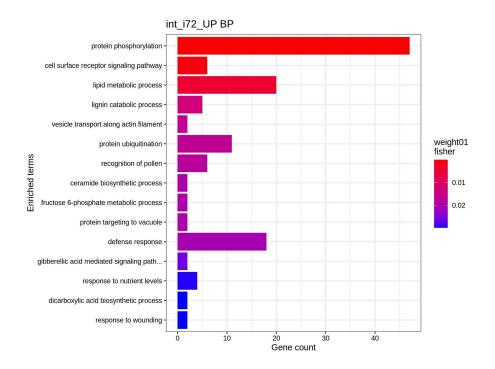
Para esto, volvemos a Attributes (1), HEADER INFORMATION (2), y elegimos las opciones mencionadas (marcadas con *). Luego volvemos a Results y descargamos nuevamente nuestro FASTA.



Si exploramos los encabezados, ahora tienen más información (cada campo

separado por pipe, "|")

6. Tenemos este gráfico de enriquecimiento GO, donde se ven los procesos biológicos enriquecidos en los genes de nuestra lista de DEGs upregulados a las 72h post infección con el hongo. Vemos que "protein fosforilation" es el término más representado. Averiguar qué genes de mi lista tienen ese GO BP (NOTA: el código es GO:0006468. Para buscar términos GO, ir a https://www.ebi.ac.uk/QuickGO/).



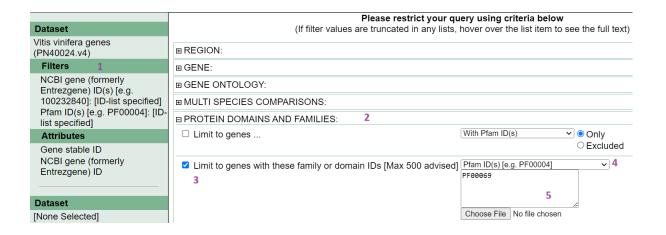
Para esto, debemos volver a modificar nuestros filtros. Vamos a filters (1), dejar el filtro de GENE como estaba y sumar GENE ONTOLOGY (2), seleccionar GO term accession (3) y escribir nuestro GO de interés en el casillero (4). Luego descargar los atributos que queramos para esos genes (ejemplo, su Gene stable ID y si NCBI Gene ID).

Dataset Vitis vinifera genes	Please restrict your query using criteria below (If filter values are truncated in any lists, hover over the list item to see the full text)	
(PN40024.v4)	⊞ REGION:	
NCBI gene (formerly Entrezgene) ID(s) [e.g. 100232840]: [ID-list specified] GO Term Accession (e.g. GO:0050789) [Max 500 advised]: [ID-list specified]	⊞ GENE:	
	□ GENE ONTOLOGY: 2	
	GO Term Accession (e.g. GO:0050789) [Max 500 advised]	GO: 0006468 4
Attributes		Choose File No file chosen
Gene stable ID NCBI gene (formerly Entrezgene) ID	☐ GO Term Name [e.g. regulation of biological process]	
	☐ GO Evidence code	IBA A IDA IEA
Dataset		IEP
[None Selected]		IGI ▼

7. Averiguar cuántos genes de mi lista codifican para quinasas.

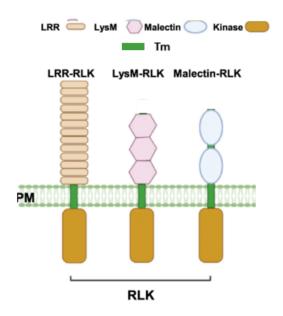
Para esto, tenemos que saber cómo identificar una quinasa. Una forma es conociendo sus dominios, y cómo están codificados en alguna base de datos de dominios. Una de las BD más usadas para esto es PFAM, y el dominio quinasa es PF00069. Podemos filtrar entonces nuestros genes para quedarnos solo con aquellos que tengan ese dominio.

Para esto, ir a Filters (1), dejar el filtro de GENE como estaba y ELIMINAR el de GENE ONTOLOGY del punto anterior, ir a PROTEIN DOMAINS AND FAMILIES (2), seleccionar Limit to genes with these family or domains IDs (3), seleccionar en el desplegable Pfam IDs (4, ojo pueden usar cualquier otra DB, como Interpro, PANTHER, etc, sabiendo el ID del dominio quinasas), escribir en el casillero nuestro Pfam de interés (5, ojo que es sensible a mayusculas y minusculas... se escribe PFXXXX).

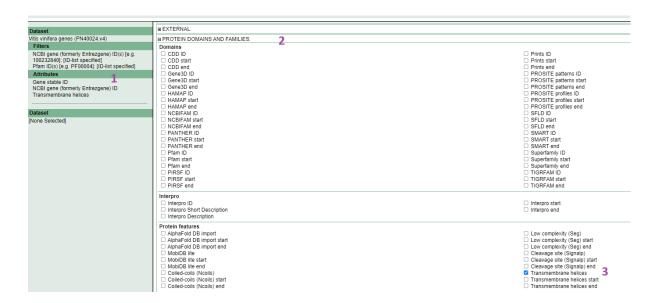


8. Identificar cuáles de estas quinasas DEG tienen dominios

transmembrana, como posibles RLK (receptor like kinase, proteínas que participan en procesos de defensa a patógenos en plantas).

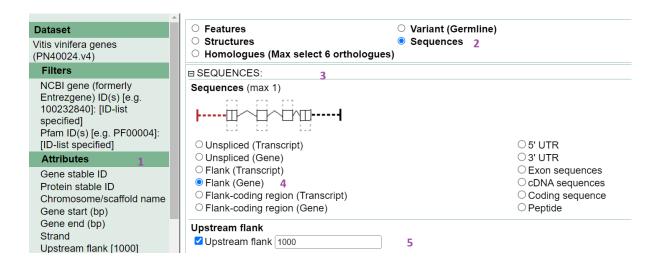


Para esto, dejar intactos nuestros filtros (i.e. el de GENE y el de GENE ONTOLOGY, e ir a Attributes (1), seleccionar PROTEIN DOMAINS AND FAMILIES (2) y elegir Transmembrane helix (3). Results y Go para descargar.



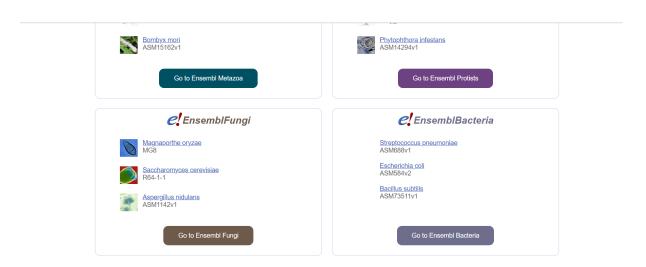
9. Recuperar en formato FASTA (nucleótidos) la región río arriba de cada una de estas quinasas (1000 pb rio arriba)

Para esto, ir Attributes (1), seleccionar Sequences (2), desplegar SEQUENCES (3), seleccionar Flank (Gene, 4) y luego en Upstream flank poner los pb deseados



Actividad 3.

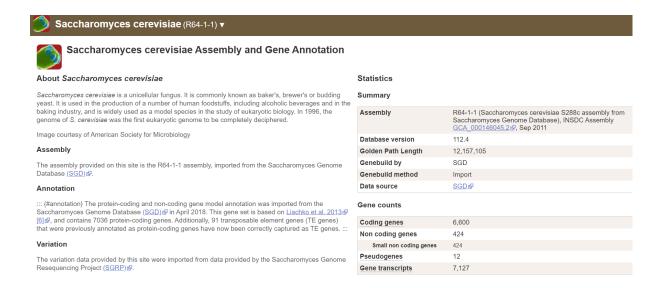
1. Encontrar el sitio para S. cerevisiae



Vamos a estar trabajando en Ensembl Fungi (https://fungi.ensembl.org/Saccharomyces cerevisiae/Info/Index.

2. Registrar el nombre del *assembly* (genoma de referencia), su tamaño en pb, número de cromosomas y cantidad de genes anotados (pista: More information and statistics)

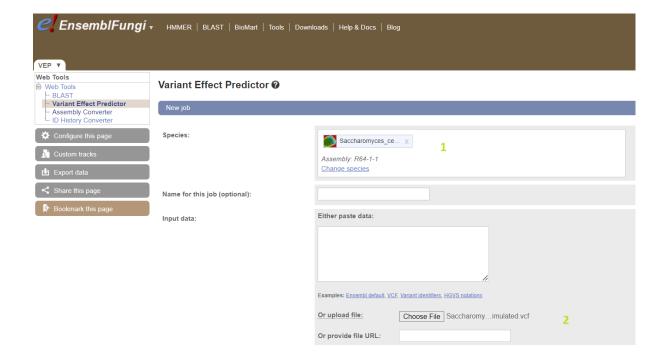
Assembly R64-1-1, INSDC Assembly GCA_000146045.2, Sep 2011. Genome Length: 12,157,105. Coding genes: 6600



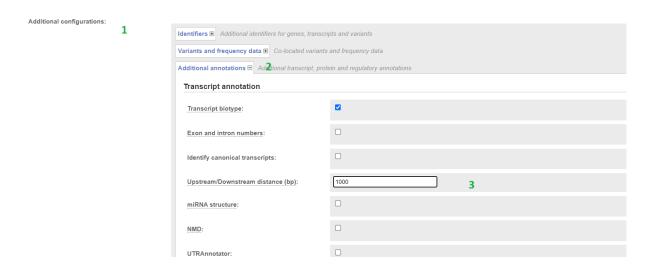
Actividad 4.

 Usando VEP, predecir el efecto de las variantes disponibles en el VCF (descargar el VCF del GitHub de RSG Uruguay)

Para esto, ir a Tools (barra superior), seleccionar VEP. Luego elegir la especie (1, *S cerevisiae* está por defecto, pero si quisieran elegir otra ir a "change species"). Luego subir los datos en el formato aceptado (uno de ellos es VCF, variant call format, y es el formato de nuestro archivo, así que directamente lo subimos desde Upload file (2).



Si bien podemos ejecutar por defecto, vamos a cambiar algun parametro (Aditional configurations, 1). En este caso, vamos a modificar cómo define las relaciones Upstream/ downstream (additional annotations, 2): en vez de usar 5000 pb (defecto) usaremos 1000 pb (3).

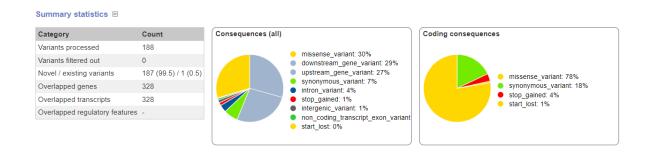


Luego Run (botón verde inferior) y esperamos (va a pasar de estado qued, a running, a done)



2. ¿Cuántas variantes tiene nuestro archivo?

Teníamos 188 variantes, como se ve en la tabla de estadísticas resumen.



3. ¿Cuáles son las consecuencias más frecuentes?

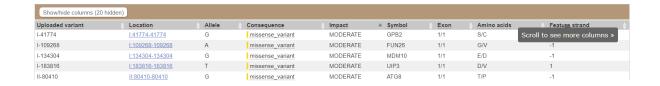
Segun el gráfico de torta superior, missense variants (30%), seguido de las downstream (29%), seguido de las upstream (27% de las variantes)

4. ¿Cuántas variantes generan un "missense_variant"? (pista: usar filtros, consequences)

Podemos usar el filtro por consequences, y pedir missense_variant



Recuperamos múltiples variantes:



5. ¿Cuántas variantes son de impacto alto (HIGH)? Cuáles son sus consecuencias? (Ojo que los filtros son sensibles a mayúsculas/ minúsculas)

Nuevamente podemos filtrar, ahora por impacto (HIGH). Presionar add



Recuperamos estas seis (6) variantes, dos de stop_gained y una start_lost



6. Hay variantes que afectan el gen de la PDC1 (Pyruvate Decarboxylase 1)? (pista: su genelD/Symbol es PDC1, y está en cromosoma XII: posiciones 232390-234081)

Podemos filtrar por Symbol:



O por location (XII:232390-234081, se escribe cromosoma:inicio:final, sin espacios).

En cualquiera de los casos es lo mismo, no hay variantes que afecten a ese gen. Podemos extendernos y mirar 1000 pb rio arriba o abajo location (XII:231390-235081) pero da lo mismo.



Actividad 5 (integradora)

1. No encontramos variantes que afectan el gen de la PDC1... pero quizá a alguno de sus parálogos? (Si es que tiene).

Buscar los parálogos de PDC1. Si hay varios, quedarse con el de mayor % de similitud (pista: BioMart) → luego VEP p/ variantes, y sus consecuencias)

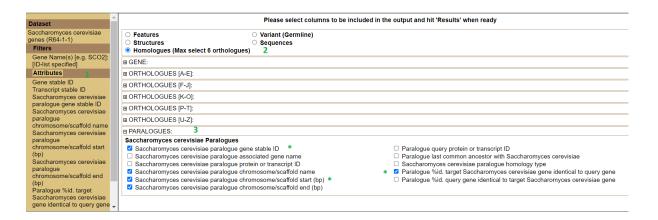
En BioMart, elegir como dataset los genes de S. cereviciae



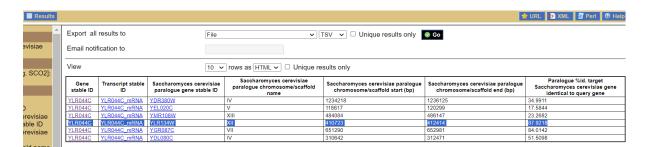
Luego en filter \rightarrow seleccionar GENE \rightarrow input external references ID list \rightarrow en el desplegable, seleccionar gene Names \rightarrow Escribir en el recuadro el nombre de nuestro gen (PDC1)



Luego eb Attributes (1), seleccionar Homologues (2), PARALOGUES (3) y los datos de los parálogos (ID, posición en el genoma (para luego podes buscar SNPs en esas regiones), % de identidad).



Luego en Results podemos ver que tiene 6 parálogos, y que el que está pintado es el de mayor similitud (posible duplicación más reciente, y mantenimiento de función).



Para buscar si hay variantes en ese parálogo, volver a la salida de VEP (queda guardada por 10 días) y filtrar por location (XII:409723-413414, con 1000 bp extra rio arriba y rio abajo)

Exploración libre de Ensembl

Finalmente, podemos explorar ese gen (usando el browser de Ensembl). Para esto, click en el correspondiente Saccharomyces cerevisiae paralogue gene stable ID (YLR134W) y se abrirá la ventana correspondiente a este gen de Ensembl Fungi, para explorarlo:

